

Interview Q&A — annotated with function calls

Q1: A client market order arrives at 10:15. Walk through it end to end.

Scenario: market BUY 2,000 shares · NBBO 3¢ wide (bid B / ask B+3) · firm position -5,000 (short).

STEP 0 — THE ORDER GETS ITS TURN (`MAIN.MERGE_EVENTS`)

Quotes and orders are one merged stream; the `<=` tie-break dispatches every quote with $ts \leq 10:15$ **before** this order. By the time `engine.on_order(o)` is called, `engine.quote` is the prevailing NBBO and nothing after 10:15 has been read (no lookahead by construction — the engine never holds the tape).

STEP 1 — CROSS FIRST (`ENGINE._TRY_CROSS` → `STRATEGY.CROSS_WINDOW`)

Loop over the best opposite side of the internal book (`book.best_sell()`). For each candidate, `cross_window(buy_limit=None, sell_limit, bid, ask)` computes the price range satisfying both clients **and** the NBBO; if non-empty, both legs fill at the clamped midpoint (`cross_price`), two AGENCY/CROSS rows via `_fill()` . Assume no overlap here → 2,000 remain.

STEP 2 — MARKETABILITY (`ENGINE._MARKETABLE`)

`order_type == "MARKET"` → always marketable (a market order has no limit; the limit check applies only to LIMIT orders). Enter `_execute Marketable` .

STEP 3 — PRINCIPAL DECISION

(`STRATEGY.PRINCIPAL_QUOTE(ORDER, POSITION=-5000, TS, BID, ASK)`)

All four inputs matter:

- $\text{spread} = 3 \geq \text{min_internalize_spread}$ (2) ✓
- $\text{ts} < \text{no_new_risk_after}$ (15:55) ✓
- **direction:** client BUY $\Rightarrow$ firm SELLS $\Rightarrow$ position goes MORE short. This is *new risk* (branch A), not inventory-reducing — reduces would need $\text{position} > 0$ for a BUY.
- **capacity check:** $\text{cap} = \text{position} + \text{hard} = -5,000 + 10,000 = 5,000 \geq 2,000 \Rightarrow$ internalize in full. (At $-8,500$ it would fill 1,500 and route 500 — the hard limit is enforced by sizing, so a breach cannot happen.)

Price = $\text{improved_price}(\text{"BUY"}, \text{bid}, \text{ask}) = \text{ceil}(\text{mid}) = B+2 = \text{ask} - 1\text{¢}$ (client saves 1¢ vs routing; odd spread $\rightarrow$ the half-cent rounds to the firm).

STEP 4 — COMPLIANCE CHOKEPOINT (`ENGINE._FILL`)

Every fill passes here before booking:

- $\text{bid} \leq \text{px} \leq \text{ask}$ (else `ComplianceError`, run dies)
- buy $\text{px} \leq \text{client limit}$ / sell $\text{px} \geq \text{client limit}$ (limit orders)
- $0 < \text{qty} \leq \text{remaining}$ Then bookkeeping: $\text{position} -= 2,000 \rightarrow -7,000$, `cash += 2,000 × px`, and `Reporter.record_fill(...)` writes the row with `nbbo_bid/nbbo_ask` columns (self-documenting compliance evidence).

STEP 5 — POST-TRADE RISK CHECK (`ENGINE._REBALANCE(TS, SOFT=6,000)`)

$|-7,000| > 6,000 \Rightarrow$ reduce 1,000, in cost order:

1. **Resting book first:** firm is short, needs to BUY $\rightarrow$ consume resting SELL limits with $\text{limit} \leq \text{ask}$ at the client's own price (`_fill(..., PRINCIPAL, INTERNAL)`) — a cheaper cover than the ask, and a fill that client wasn't otherwise getting.
2. **Market for the remainder:** `_firm_trade(ts, "BUY", residual, ask)` — buy at the ask (side and price matter: covering a short, paying the touch), recorded in the firm blotter with `position_after = -6,000`.

ONE-SENTENCE CLOSE

"2,000 shares fill PRINCIPAL/INTERNAL at ask-1¢ through the `_fill()` assertion, position -5,000 → -7,000 breaches the soft band, `_rebalance` covers 1,000 via resting sells then BUY @ask, ending at -6,000 — every row in `fills.csv` / `firm_trades.csv` via `Reporter`."

GOTCHAS THE INTERVIEWER WILL PROBE

1. **Sign of the position:** client BUY deepens a short (-5,000 → -7,000). Saying "7,000" without the sign reads as a direction error.
2. **Capacity check before internalizing** — the hard limit is a sizing rule, not an after-the-fact alarm.
3. **Rebalance is resting-book-first**, market second; the hedge has a side and a price (BUY @ask), not just "execute in market".
4. **Market orders have no limit price** — marketability is trivially true; don't reach for a limit check.

FULL CALL TRACE

```
merge_events                # quotes ≤ 10:15 already applied
└ Engine.on_order(o)
  └ Engine._try_cross(o)    # book.best_sell /
Strategy.cross_window/cross_price
└   └ Engine._fill x2      # (if overlap: AGENCY/CROSS both
legs)
  └ Engine._marketable(o)   # MARKET → True
  └ Engine._execute_mactable(o)
  └   └ Strategy.principal_quote(o, -5000, ts, bid, ask) → (2000,
ask-1¢)
    └   └ Engine._fill(PRINCIPAL, INTERNAL) # NBB0+limit asserts, pos
-7,000
      └   └   └ Reporter.record_fill
      └   └   └ (residual would route: _fill(AGENCY, MARKET) @ask)
      └ Engine._rebalance(ts, 6000)
        └ book.best_sell → _fill(PRINCIPAL, INTERNAL) @client limit #
cheaper cover
      └ Engine._firm_trade("BUY", residual, ask) # →
pos -6,000
      └ Reporter.record_firm_trade
```

Q1-追问: 为什么允许在 -5,000 空头时继续接 2,000 股同向新风险? 3¢ 够吗? 为什么不把软限当 internalize 上限?

结合后的答案 (我的要点 + 修正):

- 机制层 (我的回答, 正确但只是描述): -5,000 未触软限、硬限容量足够, 所以能接。
- 设计层 (必须补的一层): 软限从来不是接单闸门, 是事后目标带——sizing 只看硬限, “先接单后管理” vs “在门口拒单”才是面试官要的对比。
- 3¢ 够不够: 策略里确实没定价这件事 (诚实承认✓); 生产答案是 vol + fair-value-vs-mid 决定意愿, 用 **skew quoting** 从 50-50 mid 向公司侧偏移拿 edge, 约束 = 不出 bid/ask/客户限价 (否则 agency 严格占优)。
- 埋着的经济学陷阱: 超软限的边际 1,000 股若立即市场对冲——edge $0.5¢ < \text{对冲 } 1.5¢$, 净 $-\$10$, 不如 route。辩护三层: rebalance 先吃 resting book (成本 ≤ 0); netting 消化为主 (当天仅 20 笔市场对冲); 真正的修法是 inventory-skewed pricing 把 1.5¢ 边际 对冲成本定价进报价, 让不划算的流量被价格劝退, 而非数量一刀切。

英文背诵版: “The soft limit is deliberately a target band, not a gate... on the shares that push past the band I capture $\sim 0.5¢$ of edge while hedging at the touch costs 1.5¢ — negative expectancy if hedged immediately. Three defenses: the rebalancer exits through resting client limits first; two-sided flow nets most inventory off for free (twenty market hedges all day); and the real fix is price, not quantity — skew the quote with inventory, constrained never to go outside the NBBO or through the client’s limit, so marginally unprofitable flow prices itself out instead of a hard cutoff rejecting profitable flow along with it.”

Q1-追问 2: 钉在 -6,000 时来 BUY 2,000 还接吗? scan-resting-book 提议 / 软限会否变硬限?

- 代码答案: 接, 全额——`principal_quote` 不读软限, $\text{cap} = -6,000 + 10,000 = 4,000 \geq 2,000$; 成交后 -8,000, rebalance 立即削回。这是 EV 最薄的动作 (赌削仓走 resting/netting)。

- 我的提议（被采纳为 v0.1）：先 scan resting book, internalize qty = room-to-soft + 有利可图的 coverage (resting sell limit $\leq$ 成交价), 其余 route——直接接再 rebalance 的 net benefit 不变、client 吃掉 firm P&L”的判断数学上成立（同 tick 零和转移 1¢/股）。
- 实证：v0→v0.1 内部化 -21,300 股 = v0 对冲股数（精确对账）；对冲 20→0 笔；P&L +\$343 = 客户改善 -\$343。
- 软限变硬限？模拟器“即时对冲”假设下：是，10k 沦为摆设；生产里对冲需要时间，6k-10k 是 hedge-in-flight 工作区，硬限重新必要——同一参数在不同假设下语义会变。

Q2: 生产化（500 symbol、真实 feed）——第一个断掉的是什么？

结合后的答案（我的三点 + 修正与补充）：

- 我的三点：① per-symbol 参数（6k/10k 是 AAPL 专属，应 ADV/vol 驱动 notional limit）——对但属参数问题排不到第一；② infinite-size-at-touch 假设坍塌——对，且连带击穿收盘必平保证和 bleed 成本模型；③ 每 tick 的 ToB 更新——方向对但 heapq 是 $O(\log n)$ 不是 $O(1)$ （peek 才 $O(1)$ ），且真正的热点不在这。
- 第一个断的（漏答）：`book.coverage()` 的 $O(N)$ 线性扫描，每次 marketable 执行调一次——500 symbol × 千级 resting × 万级 tick/s 的第一个 CPU 悬崖。修法：传 cap early-exit（一行）；根治用价格档聚合/Fenwick $O(\log P)$ 。
- 架构上第一个断的假设：事件处理零耗时——单线程同步循环积压 → NBBO 陈旧 → “合规”成交变违规。
- Keep / throw：保留 strategy（纯函数）、book、engine 机制（每 symbol 一实例，零共享状态，多进程绕 GIL）；扔 data.py 整表加载和 merge_events（回放专用），Reporter 改异步 journal。

追问三连（我的问题 + 确认的答案）：

- sweep 用 peek：堆顶最优单大概率不可执行必须留在书里，消耗只走 _fill 扣量 + 懒删除；安静 tick 摊还 $O(1)$ ，全天 $O(M \log M)$ 与 tick 数解耦。
- coverage 时机：每次 marketable 执行（非每 tick）；early-exit 要传 cap（heap 底层 list 无序，不能按价升序白嫖）；v0 不用 coverage 确实省调用——但正解是“先用 $O(N)$ 买正确性，再用聚合结构买回成本”。

- Reporter 异步：有界队列 + 独立 writer 批量落盘 (WAL + seq no, 重启重放恢复)；quote 用 **conflation** (1-slot mailbox, latest wins, 决策对 quote 是 Markov 的所以合法)；**order 一条不能丢**——双通道：quote conflated、order 无损队列优先。

Q3: validate.py 证明了什么、抓不到什么？三类全绿放行的 bug

模范答案（本题未作答）：

它证明“所有已发生的成交合法且自治”——审计 commission, 且假设解析正确。三类盲区：

- 不作为之罪**：删掉 route 残量的两行 / sweep 的 $\geq$ 写成 $>$ ——该成交的没成交，已记录的行全部合规 → 全绿。修法：完备性不变量审计（独立 oracle 重放“到达时 marketable 必须全量成交”）。
- 共模失效**：validator 与引擎共享 data.py——loader 把 bid/ask 读反，两边错得一致 → 全绿。真独立要求从字节开始的第二套解析。
- 合法但错误**：improved_price 改成恒 at ask（客户零改善）/ reduces 符号写反（重仓方向加仓）/ IOC 忘取消稍后合法成交——全部在 NBBO 内 → 全绿。合规边界 $\neq$ 策略正确性 $\neq$ 客户指令忠实执行。

收尾句：validate.py 证明“没有一笔违法成交”，对漏做的事、共享代码的共同错觉、合法区间内的错误决策三者天然失明——防线的价值恰恰在于知道每道防线不防什么。

Q4: Cross 定价——resting SELL 244.79 × incoming BUY 244.83, NBBO 244.78/244.82

结合后的答案（我的回答 + 修正）：

- 成交价 = 244.80, 不是我算的 244.81**：cross_price 锚定 NBBO mid $(bid+ask)//2 = 244.80$, 不是两个限价的 mid；窗口 lo = $\max(bid, 244.79) = 244.79$, hi = $\min(ask, 244.83) = 244.82$ （上界被 ask 卡住不是买方限价）。244.80 在窗口内，免 clamp。教训：报数字前先跑一遍自己的代码。
- 改善分配**：vs touch 双方各 +2¢（对称）——锚定市场公允价平均分，刻意无视先来后到与限价激进度；限价只在 clamp 时起作用。

3. 行为分析（我答“maker 不会变”，漏了本质）：**我们的 cross 就是 midpoint dark pool**。交易所惯例 maker 只拿自己的限价（改善全归 taker）；midpoint 规则给 maker 优于 限价的价——对 maker 慷慨，代价由 taker 让渡，公平性无碍。真正的扭曲：卖方限价 $\leq$ mid 时收到的都是 mid $\rightarrow$ **激进化报价免费**（提高被 cross 概率、不损价格） $\rightarrow$ 理性 maker 压价到 mid 附近；随之而来 dark pool 的已知弊病：**quote fade / NBBO mid 操纵**可以移动内部 cross 成交价。我答对的部分：更 passive（卖方抬价）降低 fill likelihood；MM 在交易所同样无 improvement、只有 fee 差异。

收尾句：midpoint cross 的公平性没问题——它比交易所惯例对 maker 更慷慨；要审视的是激励（免费激进化）与可操纵性（mid 依赖），这正是真实 midpoint venue 挂 anti-gaming 逻辑的原因。

Q4-补充: CLAMP 的含义与 MID 出窗的情形

`cross_price` 一行：`px = min(max(mid, lo), hi)` —— 把 NBBO mid “夹”进窗口，只挪到最近的合法边界为止。

例：NBBO 244.88/244.92（mid 244.90），sell limit 244.91，buy limit 244.93：lo = $\max(244.88, 244.91) = 244.91$ ；hi = $\min(244.92, 244.93) = 244.92$ （ask 卡上界）；mid 244.90 < lo $\rightarrow$ clamp 上抬 $\rightarrow$ **成交 244.91**。

mid 位置	成交价	改善分配
窗口内	mid	双方对称
mid < lo（卖方限价/bid 绑定）	lo	卖方恰拿限价，改善倾斜给买方
mid > hi（买方限价/ask 绑定）	hi	买方恰拿限价，改善倾斜给卖方
lo > hi	不 cross	window 为 None $\rightarrow$ internalize/route

被 clamp 的一方拿到恰好自己的限价（对比 route 仍更优：本例卖方 vs bid +3¢）；剩余改善全部归对方（买方付 244.91，比限价好 2¢、比 ask 好 1¢）。细节：本例买方 limit $\geq$ ask 本身 marketable，但 `_try_cross` 排在 marketability 判断之前 $\rightarrow$ 先 cross 在 244.91，比 route 还好 1¢——“cross 优先”价值的具体展示。

Q5: Desk head 问”明天的期望 P&L 是多少？数、区间、置信来源”

结合后的答案（我的洞察 + 补上的报数纪律）：

- **我的亮点（保留）：**库存方向不是巧合——仓位 $\equiv$ -净客户流，客户流是市场压力 缩影，策略结构性站在压力对面；压力冲击若暂时则 drift 期望为正。**引用自己的 markout 证据：**internalized flow 10min markout -4.25¢/股（价格向客户反方向回归）。
- **模范报数：**
 - Edge： $E \approx +\$400/\text{天}$ ， $\sigma \pm \$150$ （今天 $\$379 = \text{客户侧 } +\$460 - \text{对冲 } \$82$ ；驱动 = volume $\times$ spread 分布，日间稳定）——策略的”工资”；
 - Drift： $E \approx 0$ 到小正（martingale 下 0；uninformed-flow 下为正，markout 支持但 $n=1$ 不许入账）； $\sigma \approx$ 时间加权 $|\text{pos}| 1,456 \times \text{日内路径 } \$2-3 \approx \pm \$3-6\text{k}$ ；尾部被 band 封顶 $\approx \pm \$15\text{k}$ ；
 - **合计： $E \approx +\$400$ ， $1\sigma \pm \$5\text{k}$ ，尾部 $\pm \$15\text{k}$ ；今天 $+\$15\text{k}$ 是一次 $+3\sigma$ 实现。**
- **口径纠错：**对 mid 的 edge 是 $0-0.5\text{¢}/\text{股}$ （+touch 半点差），”1-3¢”是对 touch 的客户改善口径——别混。
- **Run/no-run（别答成改进清单）：**跑——edge 期望独立为正、drift 尾部有界；预算与考核锚定 edge（ $\sim \$400/\text{天}$ ），drift 记噪声；优先级 = 压缩 drift 方差（skew、vol-band），并积累多日 markout，显著后才把回归溢价计入期望。

模板： $E(\text{edge}) + E(\text{drift}) \pm \sigma(\text{drift})$ ，尾部 = band $\times$ 极端路径，最后一句 run/no-run。

Q5-补充: $\sigma(\text{drift})$ 的推导与精确计算

公式： $\text{drift} = f_{\text{pos}} \cdot dP$ ；鞅 + 仓位与未来增量独立的假设下 $\sigma(\text{drift}) = \sigma_P(\text{daily}, \text{RV口径}) \times \text{pos_RMS}$ ，其中 $\text{pos_RMS} = \sqrt{f_{\text{pos}}^2 dt / T}$ 。

今天的数据（v0.2）：

- σ_P ：tape 逐 tick mid 增量平方和开根（realized variance）= $\$1.50/\text{天}$ ；
- $\text{pos_RMS} = 2,203$ 股（高于时间加权平均 $|\text{pos}| 1,456$ ——RMS 加重 4-6k 时段）；
- **$\sigma(\text{drift}) = \$3,311$** 。我口算的 $\pm \$5\text{k}$ 用了 $1\% \times \$244 \approx \2.5 的年化口径猜日波动，RV 口径只有 $\$1.50$ （当天 $\$3.2$ 高低差里有趋势段，非扩散）→ 报数应用 RV 口径。

关键读数：今天 drift \$14,699 = 4.4σ 。两种解释并列：

1. 真尾部（被设计的日子，band 钉满恰逢单边）；
2. 公式的独立性假设被违反——markout 证据（internalized -4.25¢ ）表明仓位与 后续回归正相关，该相关既抬高 $E[\text{drift}]$ 也使“ 4.4σ ”高估异常度。

金句：同一个相关性，在期望里叫流动性提供溢价，在方差公式里叫假设失效。

修正后的 Q5 报数： $E \approx +\$400$, $1\sigma \approx \pm\$3.3k$, 尾部 $\approx \text{band } 6,000 \times \text{极端路径} \approx \pm\$15k$ 。

Q6: sweep 里的 resting-vs-resting cross 分支——我们还有机会 cross 吗？

我的直觉（正确）：客户单进来时没 cross 就已经 route 走了；行情移动后变 marketable 的单被 sweep 的 marketable 分支吃掉——所以 sweep 的 cross 分支似乎轮不到。

升级为证明（当前规则下该分支不可达）：设两张 resting 单限价重叠 ($bL \geq sL$)，看后到的那张（设为卖单）到达时刻：

1. 它没被 `_try_cross` 撮合 $\Rightarrow$ 窗口空： $\max(\text{bid}, sL) > \min(\text{ask}, bL)$ ；
2. 它挂进了 book $\Rightarrow$ 非 marketable： $sL > \text{bid}$ ；
3. 由 1+2 得 $\text{lo} = sL$ 且 $sL > \min(\text{ask}, bL)$ ；又 $sL \leq bL \Rightarrow \mathbf{sL > ask} \Rightarrow bL \geq sL > \text{ask} \Rightarrow$ 先到的买单早已 marketable——但 sweep 每 tick 跑且 quote 先于 order 处理，marketable 的单不可能还挂着。矛盾。买卖对调对称。 $\Rightarrow$ 重叠的 resting 对从不共存；限价静态 $\Rightarrow$ 之后的 NBBO 移动也造不出重叠。

实证：当天 7 组 cross（14 行）的成交时间戳全部 == 后到那条腿的 arrival 时刻，sweep 的 cross 分支全天零触发。这也回答了“cross 为何只有 1,600 股”的另一半：不是撮合不积极，而是结构上 cross 的唯一窗口就是订单到达那一瞬。

不可达性依赖四个前提（任一松动它就复活）：cross-at-arrival、每 tick sweep、限价静态、quote 先于 order。三个复活场景：

1. **amend/replace**（最现实）： $\#A \text{ SELL } 244.83$ 与 $\#B \text{ BUY } 244.81$ 各自挂着（窗口空），客户把 $\#A$ 改到 244.80 $\rightarrow$ 下个 quote 的 sweep 得到窗口 $[244.80, 244.81] \rightarrow$ cross。

2. **sweep 漏跑/conflation**（生产必然）：积压导致 marketable 单没被处理，书里出现重叠——但注意此时 NBBO 往往已跑到两个限价之外，窗口仍可能是空的，说明该分支 在生产里也是低频兜底而非主路径。
3. **改设计**（speed bump / conditional order）：marketable 单停留 200ms 等对手方——打破 cross-at-arrival。代价正是我们当初拒绝的理由（扣留客户可执行订单），除非像 IEX 那样把 speed bump 作为公开披露的场地规则。

Q6-追问 1: AMEND 应该在 ON_ORDER 里处理吗？

不应该——独立入口 `on_amend(order_id, new_limit, new_qty, ts)`，逻辑复用。

`on_order` 假设“从未见过的新单”：跑完 waterfall 然后 `book.add()`。amend 面对已在册订单，必须先取出旧状态，且要显式实现队列优先级惯例：改价或增量 → 失去时间优先级、按新价排队尾；仅减量 → 保留原位。这条规则在 `on_order` 里没有位置放。替代方案是拆成 cancel + new（FIX 常见），代价是中间有个“两边都没挂”的窗口。两种做法改完都要立刻重跑 waterfall（新限价可能当场 marketable 或可 cross）——共享的是执行逻辑，不是入口。已写入 DESIGN production changes 第 7 条。

Q6-追问 2: SWEEP 可能跑不完时，删掉 CROSS 检查能否降延迟？

不能删——但直觉指向的优化方向对，只是位置错了。

1. 它已近乎免费：两个 `best_*` peek ($O(1)$)，且本来就要取来做 marketable 判断）加一次纯算术 `cross_window`；删掉省几十纳秒。同一函数里真正贵的是 `_execute Marketable` → `coverage()` 的 $O(N)$ 扫书——要砍延迟砍那个。
2. 逻辑自相矛盾：它不可达恰恰依赖“每 tick sweep 完整跑”；一旦假设 sweep 会漏跑（正是删它的理由），重叠就可能出现，此时被删的分支正是最后的守卫。
3. 正解是分层不是删除：快路径只做 NBBO 更新 + top-of-book 可执行性判断；cross 检查/coverage/bleed 用脏标志（`crossable_dirty`）或定时器移出快路径，让 99% 的安静 tick 走最短路径。

金句：删除一个不可达分支的收益是纳秒级，代价是把隐式不变量变成隐患——尤其当你删它的理由，恰好也是它可能变得可达的理由。

Q7: coverage 项是怎么变成死代码的（自省案例）

需求来源：v0.1 讨论中我提的复合需求——“resting book 没有 offsetting order 是否不接？或者书里有多少接多少”。它含两个独立判断，被合并成了一条规则：

- **判断 A**：钉在软限之上接单 = 用 1.5¢ 对冲成本换 0.5¢ edge → 该 route。实现为 `room = 到软限的余量` —— **\$343 的改善全部来自它**。
- **判断 B**：书里有便宜对手方就多接（退出免费）。实现为 `+ coverage` —— **从未开火**。

为什么不可达：cross 优先的规则保证——只要 resting 单便宜到能对冲，来单一定先把它 cross 掉；coverage 找的集合（限价优于成交价）是 cross 可吃集合的子集。sweep 路径同理：它先跑 cross 分支，进入 marketable 分支时“存在可 cross 对手方”已被否定。

实证（插桩计数）：全天 457 次 `_execute Marketable`（on_order 299 / sweep 158），**coverage > 0 出现 0 次**。删除后 P&L、fills、hedges 完全不变（\$15,078）。

漏检的根因：v0.1 当时只验证了总量结果（P&L、对冲笔数、±\$343 精确对账），没有验证机制归因。一句“这 \$343 里 room 和 coverage 各占多少”就能当场暴露。

教训（已写入 workspace 与 _template 的 CLAUDE.md）：新增 function/branch 时，在测试运行里统计其**实际调用次数**并分析是否真的需要——总量对账证明结果，不证明机制；零调用就删掉，或写明为何不可达、什么条件下会复活。

处理：删除 `coverage` 参数、`book.coverage()`（heap 版）与相关调用；`book_dict.coverage()` 保留为深度查询，docstring 标注“引擎不使用，实测 0/457”。顺带消灭了 Q2 里点名的那个 O(N) CPU 悬崖——那个悬崖本来就是为一个死项付的钱。

Q8: 非 marketable 的盘中限价单能否 internalize ? (v0.3)

问题：NBBO 244.40/244.44，客户 BUY @244.43 → `_marketable` 为假 (< ask)，直接挂 book。但 `improved_price` = mid **244.42 ≤ 244.43**，合法且对客户严格更优——我们放过了一笔双赢成交。

为什么原设计漏掉：“marketable”被我借用得过窄：交易所语义是“能立刻与外部成交”，我用它当成了“客户是否急于成交”的代理，把盘中限价单默认解读为耐心挂单者。但客户的限价 244.43 已明确表达“244.43 及更好都接受”，244.42 严格更好——用“他可能想等更好的价”拒绝一个严格更优的成交，是替客户猜意图。真实 midpoint venue（IEX D-Peg 等）正是靠给盘中挂单提供 mid 成交获客。

原路径的补偿：这类单多数最终仍被 `_rebalance` 吃掉（公司减仓时按**客户限价**成交），但价格是 244.43 而非 244.42，且要等到公司恰好想减仓。

v0.3 实现：`on_order` 的 `_marketable` 分支加 `elif` → `_offer_midpoint()`：若 `improved_price` 满足客户限价 $\wedge$ `principal_quote` 给出的正是该改善价（排除 touch 分支）→ 成交；否则照常挂单。无 route 腿。

调用计数（按 CLAUDE.md 新规矩必做）：199 次调用 → **13 笔成交、9,000 股**。关键的诚实发现：**13 笔全部是 2¢ 点差、客户限价恰好等于 mid** ⇒ 相对客户自己限价的改善是 **\$0.00**，客户得到的是“立刻成交”而非更好的价；相对 touch 则是 +1¢。我举的 4¢ 例子（limit 244.43 / mid 244.42）当天一次也没出现。

全天影响（v0.2 → v0.3）：P&L \$15,078 → **\$15,307**；客户改善 \$1,935 → **\$2,013**；成交股数 477,100 → 478,100（IOC 取消 -1,000）；对冲 17 → 19 笔。

风险（必须一并说）：这会放大内部化量与逆向选择敞口——耐心挂单者往往比 marketable 单更 informed（他们在选价而不是抢时间）。生产上应配 markout 分层而非无差别打开。与 v0.1 的方向恰好相反：v0.1 收紧接单，v0.3 放宽接单。

具体数据例子：一个 ORDER 事件与一个 QUOTE 事件的完整触发链

A. Order 事件——ORD-00004（真实数据，v0.3 新增路径） 到达 09:31:20.121, BUY 100 LIMIT @244.85；此刻 NBBO **244.84/244.86** (2¢)，公司仓位 **-300**。

```

merge_events                                     # ≤09:31:20.121 的 quote 已全部先行处理
└ Engine.on_order(o)
  └ _try_cross(o, ts)                            # book.best_sell() → None (无对手方) → 立即
返回
  └ _marketable(o)                              # 244.85 < ask 244.86 → False
  └ _offer_midpoint(o, ts)                      # ← v0.3 新分支
    └ improved_price("BUY", 24484, 24486) = ceil(mid) = 244.85
    └ 244.85 ≤ limit 244.85 ✓ (恰好等于, 非严格更优)
    └ principal_quote(o, -300, ts, ...) → (100, 244.85)
      spread 2 ≥ 2 ✓ / 未过 15:55 ✓
      hard_cap = -300+10,000 = 9,700; room = -300+6,000 = 5,700
      qty = min(100, 9,700, 5,700) = 100
    └ _fill(ts, o, 100, 244.85, PRINCIPAL, INTERNAL)
      └ 断言 24484 ≤ 24485 ≤ 24486 ✓; 买价 ≤ 限价 ✓; 0 < 100 ≤ 100 ✓
      └ position -300 → -400; cash += 100 × 244.85
      └ Reporter.record_fill(... nbbo_bid=244.84, nbbo_ask=244.86)
  └ o.remaining == 0 → 不挂 book、不取消
  └ _rebalance(ts, 6000)                        # |-400| ≤ 6,000 → 首行 return (空转)
  └ _track_inventory_age(ts)                    # |-400| ≤ bleed_trigger 4,000 →
_over_since = None

```

客户结果：立刻全成 @244.85，比 route (ask 244.86) 好 1¢；原版本下这单会挂进 book 等行情。

B. Quote 事件——09:45:00.001 的 tick (触发 bleed hedge) 新 NBBO 244.51/244.52 (1¢)，进入前公司仓位 -5,900 (上午空头累积)。

```

Engine.on_quote(q)
├─ self.quote = q                # NBB0 快照替换 (0(1), 引擎只持有这一条)
├─ _sweep(q.ts)                  # while: best_buy/best_sell peek
│   ├── cross 分支: 无重叠 (Q6 证明其不可达)
│   ├── b.limit ≥ ask? / s.limit ≤ bid? 均否
│   └─ return (安静 tick, 摊还 0(1))
├─ _rebalance(q.ts, 6000)        # |-5,900| ≤ 6,000 → return (未破软限)
├─ bleed_target(spread=1, pos=-5900, over_secs=...)
│   ├── |-5,900| > bleed_trigger 4,000 ✓
│   └─ spread 1 ≤ cheap_spread_max 1 ✓ → 返回 target = 4,000 (触发器 A)
├─ _rebalance(q.ts, 4000)        # excess = 5,900 - 4,000 = 1,900
│   ├── 先找 resting SELL: best_sell().limit ≤ ask? 否 (无便宜卖单) → break
│   └─ _firm_trade(ts, "BUY", 1900, 244.52) # 市场回补, 付半点差 0.5¢/股
│       ├── position -5,900 → -4,000; cash -= 1,900 × 244.52
│       └─ Reporter.record_firm_trade(... position_after=-4,000)
└─ _track_inventory_age(q.ts)    # |-4,000| ≤ 4,000 → _over_since = None
    (计时器复位)

```

这是当天 19 笔对冲中最大的一笔，也是“挑最便宜的窗口动手”的实证：spread 恰为 1¢（全天最低），对冲成本 0.5¢/股 vs v0 时代被迫对冲的 1.8¢/股。

Q9: bleed 的双面性——降低漂移方差的同时，牺牲了减仓型 internalization 的 edge

核心发现：库存在这套策略里有**双重身份**——既是风险敞口（bleed 想消灭它），也是接收 1¢ 免费流量的产能（edge 的主力来源）。压低库存等于同时压低这项产能。

edge 的结构（实证分桶）：客户成交的每股 edge 只有两个取值：

- **偶数点差（2/4/6¢）**：edge ≡ 0 —— mid 是整数，改善价 = 精确 mid，公司零边际。当天 2¢ 桶超过 10 万股，一分不赚；
- **奇数点差（1/3/5¢）**：edge = 0.5¢/股 —— mid 落在半美分，取整判给公司。**全部 edge 来自这里**，其中 1¢ 桶（\$334 / 全部 \$503）是主力。

1¢ 桶是什么（这里修正一个容易犯的错）：2¢ 门槛只管新增风险——`principal_quote` 的 reduce 分支独立于那个 `if`，无点差门槛。实证：v0.1 中 1¢ 点差的 INTERNAL 成交涉及 92 张订单，**100% 在 touch 成交**（买 @ask / 卖 @bid），全部是减仓分支。其上限定编码为 `min(order.remaining, abs(position))` ——库存有多少，才能接多少。

v0.1 → v0.2 的代价拆解 (-\$124.5)：

- **保费 -\$81.5 (结构性确定)：**16,300 股 × 0.5¢ 半点差；触发器 A 保证每笔都在 1¢ 窗口成交，是理论最低单位成本（对比 v0 被迫对冲的 1.81¢/股）。
- **机会成本 -\$43 (路径相关)：**残差 \$503.5 - \$460.5，主项在 1¢ 桶 (-9,900 股 × 0.5¢ = -\$49.5，被 3¢ 桶 +\$6.5 抵消)。因果链：bleed 把 lposl 从常驻 4k-6k 压到 4k 以下 → reduce 分支上限变小 → 少接 1¢ 免费流量。

受影响订单 (精确定位)：15 张订单少接 10,000 股、**全部是 1¢ 点差**，其中 ORD-00053 (-1,700)、ORD-00297 (-1,500，完全归零)、ORD-00285 (-1,200) 为最大三笔；另有 8 张因 bleed 改变了后续仓位轨迹而**多接 6,300 股**——所以 **bleed 不是单向削减，而是重新分配了全天的接单容量**，\$43 是净额不是毛额。

买到了什么：时间加权 lposl 1,685 → 1,456 股； $\sigma(\text{drift}) \propto \text{pos_RMS}$ ，敞口下降 同比例压缩漂移方差。这是用确定的小额支出换不确定的大额损失概率——保险的结构。

答辩表述：“bleed 花了 \$82 的确定保费和约 \$43 的随机机会成本，买到约 14% 的敞口方差缩减。值得强调的是这两项性质不同：保费 = 对冲量 × 半点差，触发即发生；机会成本取决于当天 1¢ 时段来了多少减仓流量，换一天可能是 \$20 或 \$80。所以我分开报，不合成一个‘总成本 \$125’。”

由此得出的优化方向：数量类改动 (v0.1/v0.2/v0.3) 动不了 edge 的天花板——偶数点差 $\text{edge} \equiv 0$ 是**定价规则**决定的，而它们占内部化量一半以上。要提升 edge 只能改定价（偶数点差向公司偏移半美分，代价是客户改善从 1¢ 降到 $\text{spread}/2 - 0.5\text{¢}$ ），或按客户毒性分层定价。